

道琼斯美国指数 ARMA 模型预测

——《基于 1992-2023 年美国道指周度分析》

蒲洪基

(2021331025)

摘要：2024 开年，美股走势非常强劲，道琼斯指数和纳斯达克指数屡创新高，本篇基于美国道琼斯指数近 1992-2024 年总计 32 年数据分析建立 ARMA 模型，并以此作为预测基础，预测 2024-2034 年美国道琼斯指数发展趋势

关键词：道琼斯指数、ARMA 模型、经济预测

一、引言

美国经济，作为全球最大的单一国家经济体，其发展历程不仅对美国本身产生了深远影响，也在很大程度上塑造了世界经济的格局。自从 18 世纪末工业革命以来，美国经济经历了多次重大转变，从早期的农业经济，到工业化时期的迅猛发展，再到 20 世纪后半叶的信息技术革命，每一次变革都推动了美国经济的跃进，同时也对全球经济产生了重要影响。因此，分析美国经济走势尤为重要。

时间序列分析是一种统计方法，用于分析按时间顺序排列的数据点。这种分析方法在金融、经济、气象学、社会科学等多个领域中都有广泛的应用。时间序列分析的目的是理解过去的行为，并预测未来的趋势。在众多时间序列分析方法中，自回归移动平均模型（ARMA）是一种特别重要的工具。一方面，时间序列分析能够帮助识别数据中的趋势、季节性模式、周期性和其他结构特征，为未来的趋势提供预测。另一方面，通过分析时间序列数据，决策者可以基于历史趋势和预测结果做出更加明智的决策。


ARMA 模型结合了自回归（AR）和移动平均（MA）两种模型，提供了一种灵活且强大的方法来分析和预测平稳时间序列数据。在功能上，其灵活且简洁，ARMA 模型可以通过调整自回归项和移动平均项的阶数来适应不同的数据特性，使其能够拟合各种类型的时间序列。在预测上，其准确且广泛。尽管 ARMA 模型在处理平稳时间序列方面表现出色，

但在处理非平稳数据时可能需要先对数据进行差分或其他转换，以达到平稳性要求。此外，ARMA 模型的扩展，如自回归积分滑动平均（ARIMA）模型和季节性 ARIMA（SARIMA）模型，进一步增强了处理各种复杂时间序列数据的能力。

二、数据处理

（一）研究目标、数据来源说明与数据预处理

A 股急流勇退之际，美股自 2023 年以来逆降息周期增长，屡创新高。为探究其背后趋势并预测模型，本篇立足于宏观视角，通过选取 1992 年-2024 年道琼斯美国指数，以周为单位，总计形成 1685 个样本。在探究和研究美国道琼斯指数在过往 32 年内呈现何种序列状态是，我们希望建立 ARMA 模型，预测未来 10 年道琼斯美国指数表现，最终希望给出一个相对公允的结果和预测方向。



（图 1：收盘价趋势图）

本篇数据均来源于 Wind 数据美国证券指数数据库。如上图所示，道琼斯美国指数的收盘价在 1992 年-2024 年存在明显上升趋势项，无明显季节趋势，是非平稳序列，因此在这里预设需要对该变量（收盘价）进行平滑处理。在实际图表解读方面，我们可以看到，美国 1990 年后的科技创新和互联网革命又一次推动了经济的增长，但进入 21 世纪，美国经济面临了一系列新的挑战，包括 2008 年的全球金融危机、制造业就业的减少、以及与中国等新兴经济体的竞争加剧。尽管如此，美国凭借其强大的创新能力和灵活的经济体制，继续在全球经济中保持着领导地位。但伴随着 2022 年疫情以来造成的对全球经济的冲击，美国道琼斯指数也呈现出大幅度下跌，但是令人惊讶的是，其并没有出现长期下跌趋势，反而迅速回升，直至进入屡创新高，从 1992 年-2024 年增值超过 1000 元，增长势头强劲。

(一) 描述性统计	
Mean	414.9254
Median	314.7200
Maximum	1284.210
Minimum	96.07000
Std. Dev.	279.8716
Skewness	1.238247
Kurtosis	3.656457
Jarque-Bera	460.8447
Probability	0.000000
Sum	699149.3
Sum Sq. Dev.	1.32E+08
Observations	1685

(表 1: 描述性统计)


如上表所示，基于对收盘价进行的描述性统计显示，该收盘价平均值为 414 元，中位数 314 元，最大值 1284，最小值 96，标准差在 96.07，偏度 1.23，峰度 3,65，加总为 699140。对数据进行进一步处理，应当剔除最大最小值。

(二) 季节调整与平滑处理

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		-0.237495	0.9922
Test critical values:	1% level	-3.963505	
	5% level	-3.412481	
	10% level	-3.128192	

(表 2: 未平滑调整前 ADF 检验)

基于上表我们可以验证和图 1 的趋势一致的结论，该图单位根检验 P 值为 0.9922，显著大于 0.05，所以表明未经季节调整前的单位根检验不通过，属于非平稳序列，需要进行季节调整和平滑处理。



(图 2: 平滑调整后图示)

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		-43.91733	0.0000
Test critical values:	1% level	-3.963505	
	5% level	-3.412481	
	10% level	-3.128192	

(表3: 平滑调整后ADF检验)

一阶差分法是时间序列分析中常用的方法，用于将非平稳时间序列转化为平稳时间序列。平稳性是许多时间序列模型，特别是ARMA模型和其衍生模型（如ARIMA）进行有效分析的前提条件。一个时间序列如果是平稳的，其统计特性（如均值、方差和自协方差）不随时间变化。非平稳时间序列的这些特性会随时间改变，使得建模和预测变得复杂和不准确。

进行差分后，通常需要通过统计测试来确认时间序列的平稳性。常用的平稳性检验方法包括两种，分别是ADF (Augmented Dickey-Fuller) Test：这是一种常用的检验时间序列单根存在性的方法，用于检验时间序列是否具有单位根，从而判断序列是否非平稳。KPSS (Kwiatkowski-Phillips-Schmidt-Shin) Test：这是另一种检验平稳性的方法，其零假设是序列是平稳的。

在上表中，经过平滑调整与一阶差分后，我们发现P值趋近于0，ADF检验通过，意味着其为平稳。但是该过程并未结束，我们还需要进行白噪声检验

(三) 白噪声/自相关检验

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	-0.067	-0.067	7.4647	0.006
		2	0.044	0.039	10.661	0.005
		3	-0.011	-0.006	10.864	0.012
		4	-0.021	-0.024	11.635	0.020
		5	-0.061	-0.064	17.965	0.003
		6	-0.006	-0.012	18.024	0.006
		7	-0.021	-0.017	18.740	0.009
		8	-0.018	-0.022	19.301	0.013
		9	-0.005	-0.010	19.346	0.022
		10	-0.019	-0.024	19.981	0.029
		11	0.047	0.043	23.749	0.014
		12	-0.025	-0.021	24.824	0.016
		13	0.008	-0.003	24.921	0.024
		14	0.022	0.023	25.764	0.028
		15	0.044	0.045	28.984	0.016
		16	-0.010	-0.003	29.153	0.023
		17	0.014	0.007	29.500	0.030
		18	-0.014	-0.009	29.837	0.039
		19	-0.035	-0.032	31.910	0.032
		20	0.059	0.062	37.870	0.009
		21	0.029	0.043	39.295	0.009
		22	0.035	0.035	41.360	0.007
		23	-0.025	-0.021	42.399	0.008
		24	0.020	0.016	43.117	0.010
		25	0.023	0.038	44.053	0.011
		26	-0.034	-0.029	46.030	0.009
		27	-0.033	-0.033	47.939	0.008
		28	0.012	0.011	48.200	0.010
		29	-0.034	-0.025	50.135	0.009
		30	-0.006	-0.006	50.201	0.012
		31	0.065	0.058	57.564	0.003
		32	0.069	0.077	65.756	0.000
		33	0.038	0.044	68.186	0.000
		34	-0.043	-0.046	71.313	0.000
		35	0.090	0.077	85.239	0.000
		36	-0.021	-0.002	86.004	0.000

(图3: 自相关函数图)

白噪声检验和自相关检验是时间序列分析中的重要工具，它们用于检测时间序列数据中的随机性和内在相关性。自相关是指时间序列中各时间点的值与其过去的值之间的相关性。自相关函数（ACF）是衡量这种相关性的工具。

根据上图所示我们发现，白噪声检验通过，P值均小于0.05，因此该序列为非白噪声序列，不需要进行二次差分，得到该模型为平稳且非白噪声序列。

三、模型构建

(一) 模型识别与定阶

同时我们聚焦于图3:自相关函数图，我们可以看到在自相关列和偏自相关列，偏自相关和自相关都是1阶截尾，所以PQ都是1，所以我们做出就是ARMA（1,1）。

(二) 模型设计

$$Y_t = C + \varphi_1 Y_{t-1} + \theta_1 \varepsilon_{t-1} + \varepsilon_t$$

(三) 回归结果

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	-0.533283	0.238884	-2.232394	0.0257
MA(1)	0.468481	0.249484	1.877798	0.0606
R-squared	0.745583	Mean dependent var		0.696839
Adjusted R-squared	0.733465	S.D. dependent var		11.78438
S.E. of regression	11.75695	Akaike info criterion		7.868548
Sum squared resid	232219.6	Schwarz criterion		7.878224
Log likelihood	-6534.233	Hannan-Quinn criter.		7.772132
F-statistic	4.928729	Durbin-Watson stat		1.997676
Prob(F-statistic)	0.007341			
Inverted AR Roots		-.53		
Inverted MA Roots		-.47		

(表4: 回归结果)

在上图我们可以看到ARMA模型中，并非全部显著，MA（1）项下P值大于0.05，该项并不通过，并且模型R²拟合优度为0.74558，拟合效果差，因此我们需要修正模型

(四) 模型修正

$$Y_t = C + \varphi_1 Y_{t-1} + \varepsilon_t$$

(五) 修正后回归结果

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	-0.066520	0.024336	-2.733361	0.0063
R-squared	0.784425	Mean dependent var		0.696839
Adjusted R-squared	0.813833	S.D. dependent var		11.78438
S.E. of regression	11.76178	Akaike info criterion		7.768775
Sum squared resid	232548.6	Schwarz criterion		7.775226
Log likelihood	-6535.424	Hannan-Quinn criter.		7.771164

F-statistic	7.471262	Durbin-Watson stat	1.994774
Prob(F-statistic)	0.006335		
Inverted AR Roots	-0.07		

(表5: 修正模型回归结果)

在上图我们发现, C和AR均通过P检验, 分别为0.0096与0.0063, 与此同时, 模型AIC和SIC分别为7.76与7.78, 该数值优于修正前模型的AIC (7.86) 和SIC (7.87), 因此我们以修正后模型作为预测模型

(六) 残差相关性检验

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.003	0.003	0.0115	0.915
		2	0.039	0.039	2.5417	0.281
		3	-0.010	-0.010	2.6965	0.441
		4	-0.026	-0.028	3.8719	0.424
		5	-0.064	-0.063	10.697	0.058
		6	-0.011	-0.009	10.917	0.091
		7	-0.022	-0.018	11.764	0.109
		8	-0.020	-0.021	12.447	0.132
		9	-0.008	-0.010	12.548	0.184
		10	-0.017	-0.020	13.022	0.222
		11	0.045	0.043	16.387	0.127
		12	-0.022	-0.025	17.190	0.143
		13	0.007	0.000	17.284	0.187
		14	0.026	0.026	18.422	0.188
		15	0.045	0.043	21.821	0.113
		16	-0.006	-0.005	21.886	0.147
		17	0.013	0.007	22.165	0.178
		18	-0.016	-0.012	22.578	0.207
		19	-0.032	-0.027	24.341	0.183
		20	0.059	0.067	30.323	0.065
		21	0.035	0.041	32.462	0.053
		22	0.035	0.031	34.595	0.043
		23	-0.021	-0.023	35.363	0.048
		24	0.021	0.020	36.085	0.054
		25	0.023	0.034	36.967	0.058
		26	-0.035	-0.034	39.056	0.048
		27	-0.035	-0.030	41.168	0.040

(图4: 残差相关图)

如上图所示, 我们给出对残差项的相关性检验, 我们发现残差项基本呈现不相关, 这些结果通常指示了一个良好拟合的时间序列模型, 其残差序列没有表现出明显的自相关性, 因此可能没有遗漏关键的时间序列结构。


四、模型评价与解释

(一) 模型评价

$$Y_t = -0.066520Y_{t-1}$$


该模型预示着，每变动 1% Y_{t-1} ， Y_t 则会变动-0.066520，令人疑惑的是在该模型中滞后项与变量呈现负向关系，也即 2024 年 4 月 9 日截止道琼斯美股指数价格为 1272.92，下一期可能为 1188.90，但这并不与短期相符，模型实际效果不佳。

(二) 预测



(图 5: 32 年长期预测)

评估模型的方式无非就是计算 MAPE，在上图中 MAPE 为 156.7%，模型预测相当不准确，模型预测效果不佳。



(图 6: 2 年短期预测)

在上图的 MAPE 计算为 112.32%，说明短期内误差较小，预测相对准确，但仍然不理想，模型存疑